

Lógica Borrosa

Introducción

IAA - LCC

bulacio@cifasis-conicet.gov.ar





Ejemplo- Supongamos que:

- Unas personas desean ir a tomar cerveza que sea barata, y
 - en un local tradicional, y
 - que el local quede cerca de su casa
- Se dispone de 4 lugares conocidos


Podemos distinguir tres conjuntos difusos

- 1) Cerveza barata
- 2) Local tradicional
- 3) Cercanía de su casa




- Una **cerveza barata** es una que cueste alrededor de \$1000 o menos
- Un **local tradicional** es un local que al menos tenga 5 años funcionando.
- Que **quede cerca** de su casa es que no quede a más de 10 cuadras


Conjunto: cerveza barata



Conjunto: local tradicional



Conjunto: cercanía de casa



Características de los locales

	Precio Cerveza (\$)	Años de servicio (años)	Cuadras
Local 1	1400	3	3
Local 2	800	7	12
Local 3	1000	4	9
Local 4	1250	5	10




	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución clásica
Local 1	0	0	1	
Local 2				
Local 3				
Local 4				

	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución difusa
Local 1	0,2	0,5	1	
Local 2				
Local 3				
Local 4				




T-norm


Conjunto: cerveza barata




Conjunto: local tradicional



Conjunto: cercanía de casa



Características de los locales




	Precio Cerveza (\$)	Años de servicio (años)	Cuadras
Local 1	1400	3	3
Local 2	800	7	12
Local 3	1000	4	9
Local 4	1250	5	10


	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución clásica
Local 1	0	0	1	
Local 2	1	1	0	
Local 3	1	0	1	
Local 4	0	1	1	

	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución difusa
Local 1	0,2	0,5	1	
Local 2	1	1	0,6667	
Local 3	1	0,875	1	
Local 4	0,5	1	1	


Conjunto: cerveza barata




Conjunto: local tradicional



Conjunto: cercanía de su hogar






	Precio Cerveza (\$)	Años de servicio (años)	Cuadras
Local 1	1400	3	3
Local 2	800	7	12
Local 3	1000	4	9
Local 4	1250	5	10

	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución clásica
Local 1	0	0	1	0
Local 2	1	1	0	0
Local 3	1	0	1	0
Local 4	0	1	1	0


	Precio Cerveza (\$)	Años de servicio	Cuadras	Solución difusa
Local 1	0,2	0,5	1	0,2
Local 2	1	1	0,6667	0,6667
Local 3	1	0,875	1	0,875
Local 4	0,5	1	1	0,5

T-norm


Conjunto: cerveza barata




Conjunto: local tradicional



Conjunto: cercanía de su hogar







Ejemplo

- Mediante la solución clásica los individuos no encuentra un local
- Mediante la solución difusa deducimos que posiblemente irán al Local 3.

Razonamiento borroso

Implicancia





Razonamiento

La lógica borrosa trata con proposiciones borrosas que asignan valores a **variables lingüísticas**.

P. Ej.:

1. Para la **variable lingüística “estatura”**, el valor “**estatura es alta**” es un **conjunto difuso A** definido sobre el universo de discurso de la variable lingüística.
2. Para la **variable lingüística “peso”**, el valor “**peso elevado**”, se define en el universo de discurso de dicha variable lingüística.



Variable lingüística

- Una variable lingüística es caracterizada por una quintupla

$$(x, T(x), X, G, M)$$

- Donde

x : Variable base (nombre de la variable)

$T(x)$: Conjunto de términos lingüísticos de x que refieren a la variable base

X : Conjunto universo

G : Es una regla sintáctica (gramática) para generar términos lingüísticos

M : Es una regla semántica que asigna a cada término un significado



Ej. De variable lingüística

- La **velocidad** puede ser interpretada como una variable lingüística
- $T(\text{velocidad})$ podría ser

$T(\text{velocidad}) = \{\text{lento, moderado, rápido, muy lento, mas o menos rápido, ...}\}$


- Cada término es caracterizado por un número difuso definido sobre un conjunto universal $X = [0, 100]$
- Podemos interpretar las etiquetas




Lento como "una velocidad menor a 40 Km/h"


Moderado como "una velocidad cercana a 55 Km/h"

Rápido como "una velocidad alrededor de 70 Km/h"

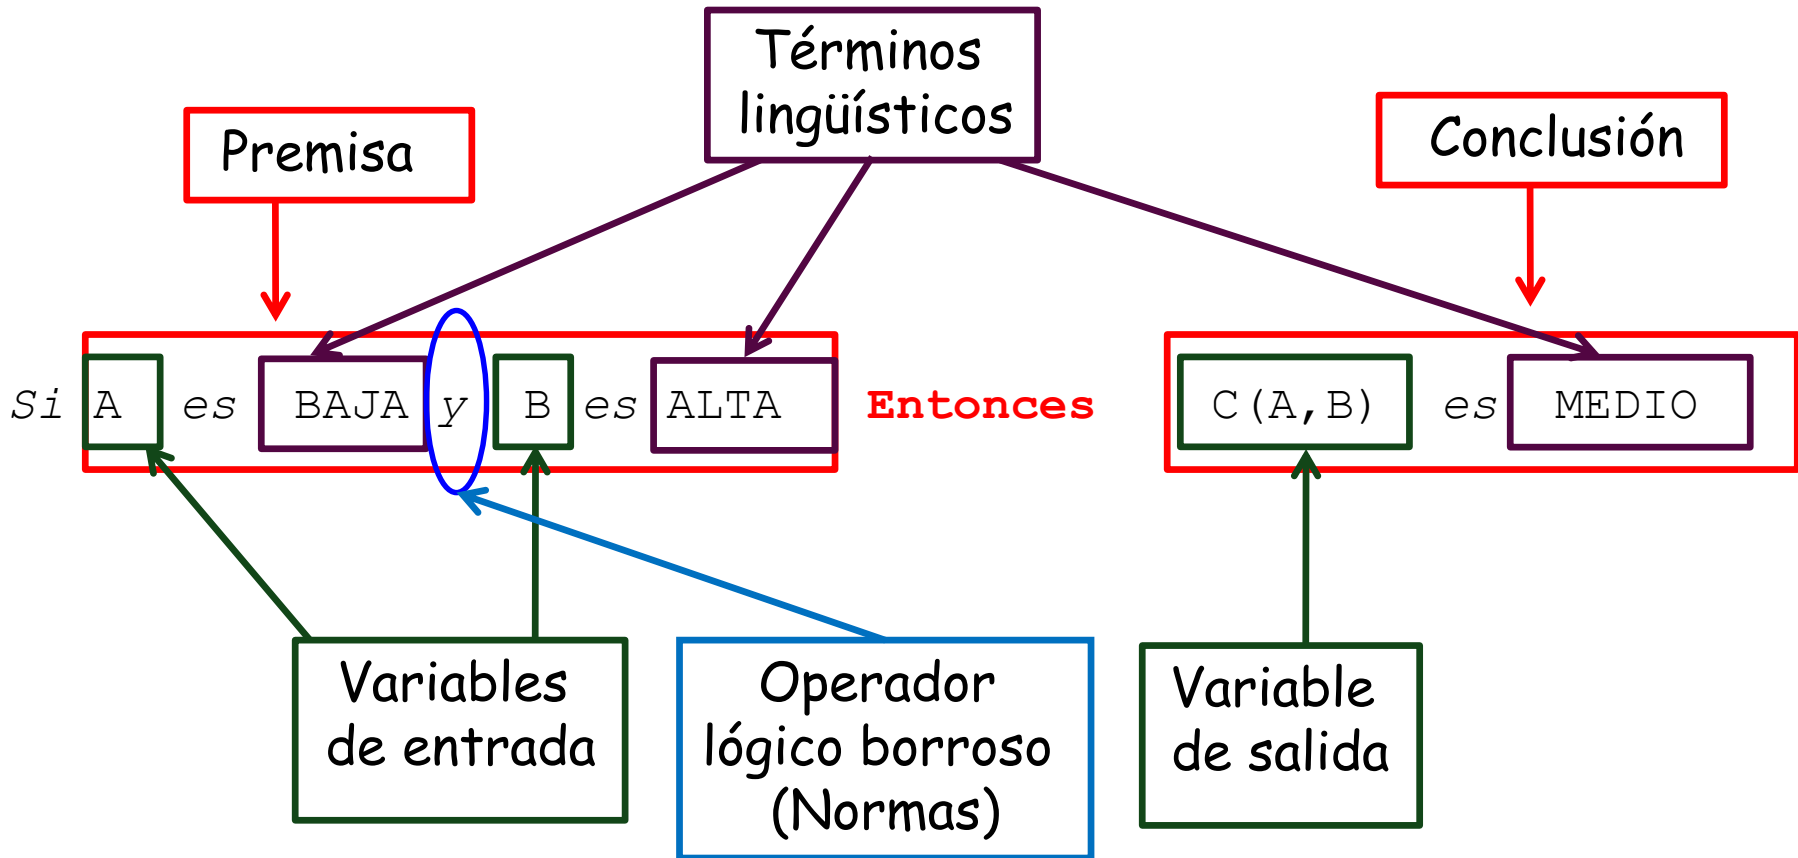


Ej. De variable lingüística





Conocimiento: representación en reglas borrosas





Implicaciones

- Definir una implicación es asignar una **función de pertenencia** a una agrupación antecedente-consecuente del tipo $P \rightarrow Q$
- Nos permite **razonar** con afirmaciones tales como:

SI “la velocidad es *normal*” **ENTONCES** “la fuerza de frenado debe ser *moderada*”



Implicaciones

- Modus Ponens Clásico

Premisa	Si P entonces Q
Hecho	P
Consecuencia	Q

- Modus Ponens Generalizado (GMP)

Premisa	Si P entonces Q
Hecho	P*
Consecuencia	Q*



Implicaciones

Opciones para definir:

- Teórica: Darle el mismo significado de **lógica clásica**.

$$P \rightarrow Q \equiv \neg P \vee Q$$

$$\mu_{p \rightarrow q}(u, v) = \max(1 - \mu_p(u), \mu_q(v))$$

$$P \rightarrow Q \equiv \neg(P \wedge (\neg Q))$$

$$\mu_{p \rightarrow q}(u, v) = 1 - \min[\mu_p(u), 1 - \mu_q(v)]$$

- Práctica: Darle un significado **causa-efecto**.

Implicación de Mamdani

$$P \rightarrow Q \equiv P \wedge Q \Rightarrow \mu_{p \rightarrow q}(u, v) = \min(\mu_p(u), \mu_q(v))$$



Implicaciones

- Implicaciones usuales:

Nombre	Fórmula
Zadeh	$\text{Max}(1-p, \text{Min}(p,q))$
Min (de Mamdani)	$\text{Min}(p,q)$
Lukasiewicz	$\text{Min}(1, 1-p+q)$
Larsen	$p \times q$

- Lukasiewicz, que se deduce de la regla:
 - $P \rightarrow Q = \neg P \vee Q$
 - $\mu_{(P \rightarrow Q)}(x,y) = \mu_{(\neg P \vee Q)}(x,y) = \text{Min}(1, \mu_{\neg P}(x) + \mu_Q(y)) = \text{Min}(1, 1-\mu_P(x) + \mu_Q(y))$
- Lukasiewicz y Zadeh son compatibles con la lógica clásica. Los de Mamdani y de Larsen no son compatibles con la lógica clásica:

p	q	Zadeh	Mamdani	Lukas.	Larsen
1	1	1	1	1	1
1	0	0	0	0	0
0	1	1	0	1	0
0	0	1	0	1	0



Implicaciones

- Mamdani y de Larsen **no** son compatibles con la lógica clásica. ¿Por qué se usan?
 - Para modelos causales donde las *consecuencias* **sólo** se dan por la aparición de las *causas* \Rightarrow es falsa la implicación **antecedente es falso** y el **consecuente verdadero**.
 - Para **hacer un modelo «implicador» como relación de causa-efecto:**

en ingeniería es falso que “falso \rightarrow verdadero”,
es falso $P \rightarrow Q = \neg P \vee Q$



Razonamiento aproximado

- Con lo visto podemos determinar las distribuciones de posibilidad de la regla según el hecho:
 - Regla: $\mu_{(P \rightarrow Q)}(x, y)$
 - Hecho: $\mu_{P*}(x)$
- Pero todavía no podemos definir la conclusión, $\mu_{Q*}(x)$, ya que para ello necesitamos componer Regla y Hecho.



- La inferencia difusa de la implicación está basada en la regla composicional de inferencia

Regla composicional de inferencia

Premisa: Si u está en P entonces v está en Q

Hecho: u' está P^*

Consecuencia: v' está Q^*

Donde Q^* está determinado por la composición

$$Q^* = P^* \circ (P \rightarrow Q)$$

matriz asociativa M



Composición M

- Con $M_{[n \times q]}$ obtenida de $P \rightarrow Q$, la inferencia difusa permite a partir de P^* (subconjunto de P), inducir un subconjunto Q^* de Q .
- Siendo $P=(p_1, \dots, p_n)$ y $Q=(q_1, \dots, q_q)$

$$M = \mu_{P \times Q} = \begin{vmatrix} p_1 \rightarrow q_1 & \dots & p_1 \rightarrow q_q \\ p_i \rightarrow q_1 & & \\ p_n \rightarrow q_1 & \dots & p_n \rightarrow q_q \end{vmatrix} \quad \text{con } p_i \rightarrow q_j = m_{ij} = \min(p_i, q_j)$$



Regla composicional

- En casos prácticos se utiliza la composición max-T-norma

$$Q^* = P^* \circ (P \rightarrow Q)$$

- Sean dos conjuntos P y Q definidos en U y V resp.

$$Q^*(v) = \max_{u \in U} \{T[P^*(u), (P \rightarrow Q)(u, v)]\}, v \in V$$

T: si existe un solo camino de conexión entre P_i^* y $(P \rightarrow Q)_{ij}$, tomamos "el menor", tramo más débil.

max: si existe más de un camino de conexión, es análogo a "si existe al menos un camino" de relaciones binarias.




$$Q^*(v) = \max_{u \in U} \{T[P^*(u), (P \rightarrow Q)(u, v)]\}, v \in V$$

- Teniendo a $P^* = (p_1^*, \dots, p_n^*)$ y $M = \mu_{P \times Q}$

$$Q^* = P^* \circ (P \rightarrow Q) = \begin{matrix} & \overbrace{\hspace{10em}}^Q & \\ \left[\begin{array}{ccc} T(p_1^*; p_1 \rightarrow q_1) & \dots & \dots T(p_1^*; p_1 \rightarrow q_q) \\ T(p_i^*; p_i \rightarrow q_1) & \dots & \dots \\ T(p_n^*; p_n \rightarrow q_1) & \dots & \dots T(p_n^*; p_n \rightarrow q_q) \end{array} \right] & \overbrace{\hspace{1em}}^P & \\ & \downarrow \text{max} & \end{matrix}$$

$$Q^* = q_1^*; \dots \dots q_q^*$$



Inferencia borrosa: Mamdani max-min

1. Entrada: valores crisp; una regla
2. Entrada: valores crisp, varias reglas
3. Entrada: una lectura borrosa



1. Inferencia max-min

(valores crisp; una regla; forma gráfica)

- **REGLA: IF A THEN B**
- Cuando A^* tiene un solo valor de pertenencia distinto de 0, p. ej., x_k se puede utilizar solo $\mu_A(x_k)$ directamente con la representación de B, $\mu_B(y)$ para inducir B^* como
 - $B^* = \mu_A(x_k) \wedge \mu_B(y)$





FIGURE 13.4 Max-min inference.



1. Ejemplo: Inferencia max-T

(valores crisp; una regla, forma analítica)

IF Temperature is normal THEN Velocity is medium

IF A THEN B

Normal temperature = $(0/100, .5/125, 1/150, .5/175, 0/200)$

Medium velocity = $(0/10, .6/20, 1/30, .6/40, 0/50)$

Obtener el resultado con la regla composicional

Normal temperature = (0/100, .5/125, 1/150, .5/175, 0/200)

Medium velocity = (0/10, .6/20, 1/30, .6/40, 0/50)



$$M = m_{ij} = \min(a_i, b_j)$$

M	100	$\min(0., 0.)$	$\min(0., .6)$	$\min(0., 1.)$	$\min(0., .6)$	$\min(0., 0.)$
	125	$\min(.5, 0.)$	$\min(.5, .6)$	$\min(.5, 1.)$	$\min(.5, .6)$	$\min(.5, 0.)$
	150	$\min(1., 0.)$	$\min(1., .6)$	$\min(1., 1.)$	$\min(1., .6)$	$\min(1., 0.)$
	175	$\min(.5, 0.)$	$\min(.5, .6)$	$\min(.5, 1.)$	$\min(.5, .6)$	$\min(.5, 0.)$
	200	$\min(0., 0.)$	$\min(0., .6)$	$\min(0., 1.)$	$\min(0., .6)$	$\min(0., 0.)$

$$= \begin{vmatrix} 0. & 0. & 0. & 0. & 0. \\ 0. & 0.5 & 0.5 & 0.5 & 0. \\ 0. & 0.6 & 1. & 0.6 & 0. \\ 0. & 0.5 & 0.5 & 0.5 & 0. \\ 0. & 0. & 0. & 0. & 0. \end{vmatrix}$$

$$A' = (0/100, .5/125, 0/150, 0/175, 0/200)$$

$$M = \begin{vmatrix} 0. & 0. & 0. & 0. & 0. \\ 0. & 0.5 & 0.5 & 0.5 & 0. \\ 0. & 0.6 & 1. & 0.6 & 0. \\ 0. & 0.5 & 0.5 & 0.5 & 0. \\ 0. & 0. & 0. & 0. & 0. \end{vmatrix}$$

$$A' = (0/100, .5/125, 0/150, 0/175, 0/200)$$

$$b'_j = \max_{1 \leq i \leq n} \{\min(a'_i, m_{ij})\}$$

$$b_1 = \max[\min(0., 0.), \min(.5, 0.), \min(0., 0.), \min(0., 0.), \min(0., 0.)]$$

$$b_2 = \max[\min(0., 0.), \min(.5, .5), \min(0., .6), \min(0., .5), \min(0., 0.)]$$

$$b_3 = \max[\min(0., 0.), \min(.5, .5), \min(0., 1.), \min(0., .5), \min(0., 0.)]$$

$$b_4 = \max[\min(0., 0.), \min(.5, .5), \min(0., .6), \min(0., .5), \min(0., 0.)]$$

$$b_5 = \max[\min(0., 0.), \min(.5, 0.), \min(0., 0.), \min(0., 0.), \min(0., 0.)]$$


$$B' = (0/10, .5/20, .5/30, .5/40, 0/50)$$




2. Inferencia max-min: valores crisp, varias reglas

Regla 1: Si caudal 1 es medio y caudal 2 es medio entonces nivel 3 es medio

Regla 2: Si caudal 1 es medio y caudal 2 es alto entonces nivel 3 es alto



2. Inferencia max-min: valores crisp, varias reglas



Regla 1: Si caudal 1 es medio \wedge caudal 2 es medio **entonces** nivel en 3 es medio


Regla 2: Si caudal 1 es medio \wedge caudal 2 es alto **entonces** nivel en 3 es alto



Completar tabla



Regla	Antecedente 1	Antecedente 2	$(A_1 \cap A_2)$
Regla 1			
Regla 2			



2. Inferencia max-min: valores crisp, varias reglas




Regla 1: Si caudal 1 es medio y caudal 2 es medio **entonces** nivel en 3 es medio

Regla 2: Si caudal 1 es medio y caudal 2 es alto **entonces** nivel en 3 es alto

Borrosificador \rightarrow Norma T: MIN

Regla	Antecedente 1	Antecedente 2	$(A_1 \cap A_2)$
Regla 1	0.49	0.2	
Regla 2	0.49	0.56	

Grado de veracidad de la regla



2. Inferencia max-min: valores crisp, varias reglas



Regla 1: Si caudal 1 es medio y caudal 2 es medio **entonces** nivel en 3 es medio

Regla 2: Si caudal 1 es medio y caudal 2 es alto **entonces** nivel en 3 es alto


Borrosificador



Norma T: MIN

Regla	Antecedente 1	Antecedente 2	$(A_1 \cap A_2)$
Regla 1	0.49	0.2	0.2
Regla 2	0.49	0.56	0.49

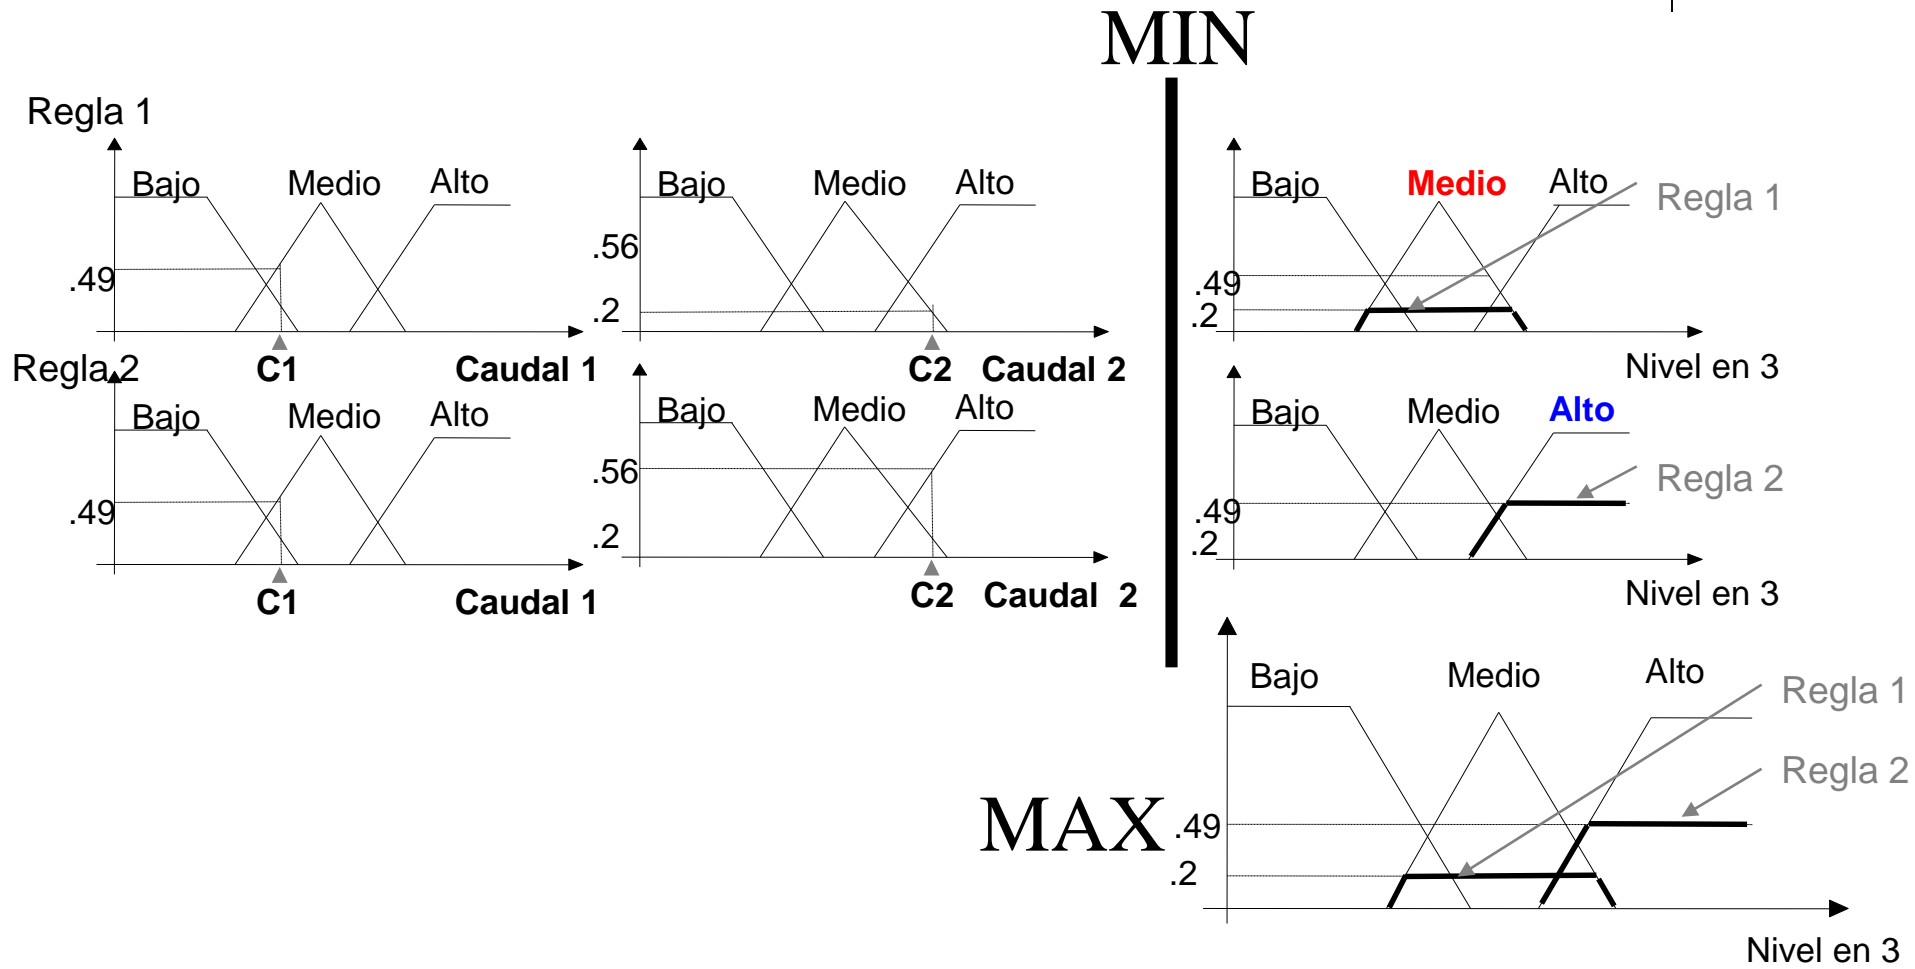
Grado de veracidad
de la regla






Regla 1: Si caudal en 1 es **medio** y caudal en 2 es **medio** entonces nivel en 3 es **medio**


Regla 2: Si caudal en 1 es **medio** y caudal en 2 es **alto** entonces nivel en 3 es **alto**



2. Inferencia max-min: valores crisp, varias reglas




Regla	Grado de veracidad de la regla
Regla 1	0.2
Regla 2	0.49



Defuzificación

Centro de área o Centro promedio



$$C3 = u^* = \frac{\sum_{i=1}^l u_i \mu_U(u_i)}{\sum_{i=1}^l \mu_U(u_i)}$$




2. Inferencia max-T: valores crisp, varias reglas



Resumiendo...


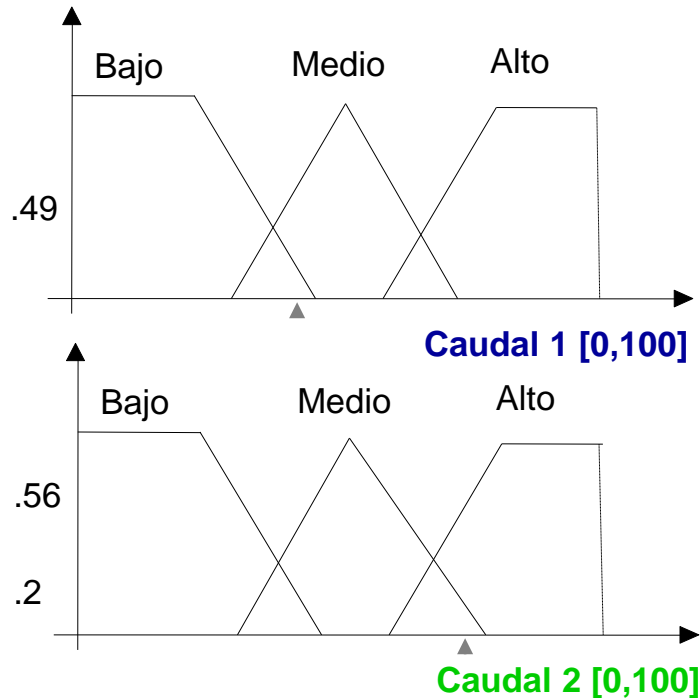




2. Ejemplo max-min: valores crisp, varias reglas

Regla 1: Si caudal 1 es medio y caudal 2 es medio
entonces nivel en 3 es medio

Regla 2: Si caudal 1 es medio y caudal 2 es alto
entonces nivel en 3 es alto



$$C1 = 45; C2 = 75$$



3. Inferencia borrosa: max-T (entrada borrosa)

En el caso que la entrada a la regla sea una lectura difusa, nosotros podemos considerar la intersección de A y A^* , es decir:

$\min(a_i, a^*_i)$ para inducir el B^*




FIGURE 13.5 Max-min inference for fuzzy input.

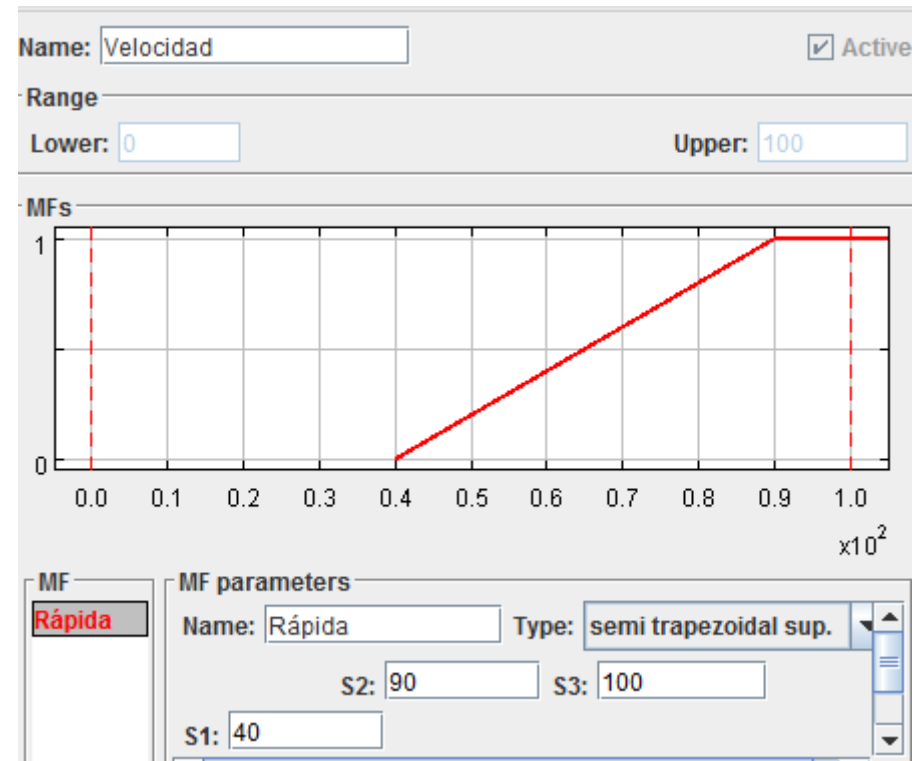
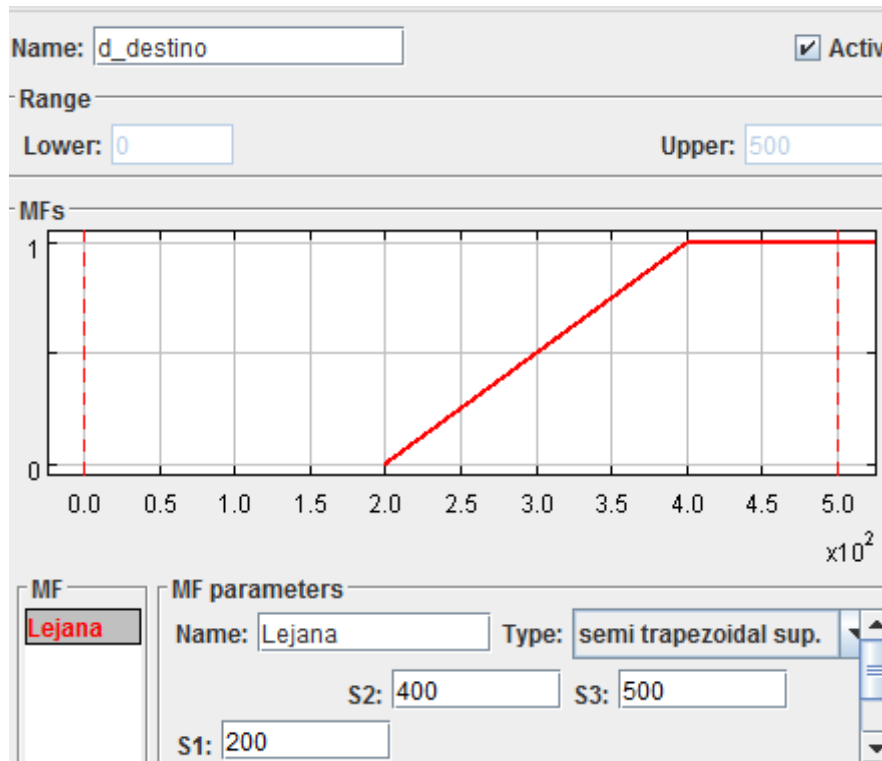
3. Inferencia borrosa: max-T (entrada borrosa)




REGLA: Si d_{dest} es lejana entonces v debe ser rápida

$$f_{lejana} = [0,25/250 \ 0,5/300 \ 0,75/350 \ 1/400 \ 1/450] \quad (P)$$

$$f_{rapida} = [0/40 \ 0,2/50 \ 0,6/70 \ 1/90] \quad (Q)$$





3. Inferencia borrosa: max-T (entrada borrosa)

REGLA: Si d_{dest} es lejana entonces v debe ser rápida

Tengo $d_{dest}^* = [0,75/250 \quad 1/300 \quad 0,75/350 \quad 0/400 \quad 0/450]$ y la matriz M , $V^*???$

MAX-min

	250	300	350	400	450
$[0,75 \quad 1 \quad 0,75 \quad 0 \quad 0]$	0,75	1	0,75	0	0
0	0	0,2	0,25	0,25	250
0	0	0,2	0,5	0,5	300
0	0	0,2	0,6	0,75	350
0	0	0,2	0,6	1	400
0	0	0,2	0,6	1	450


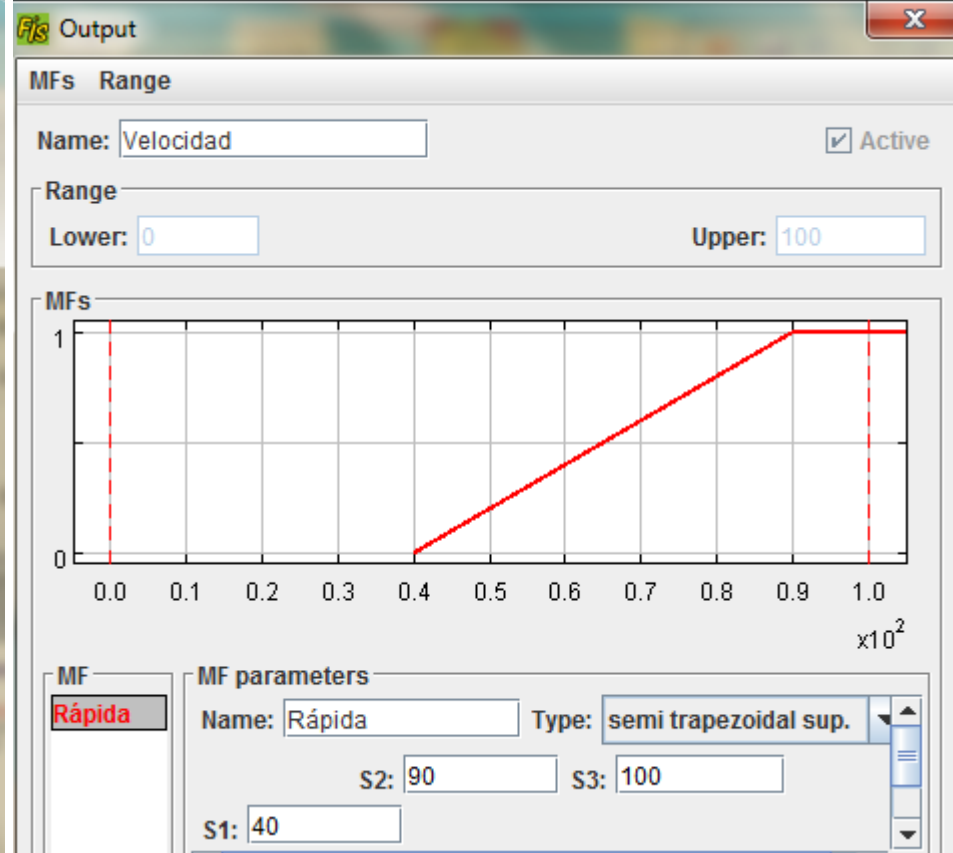
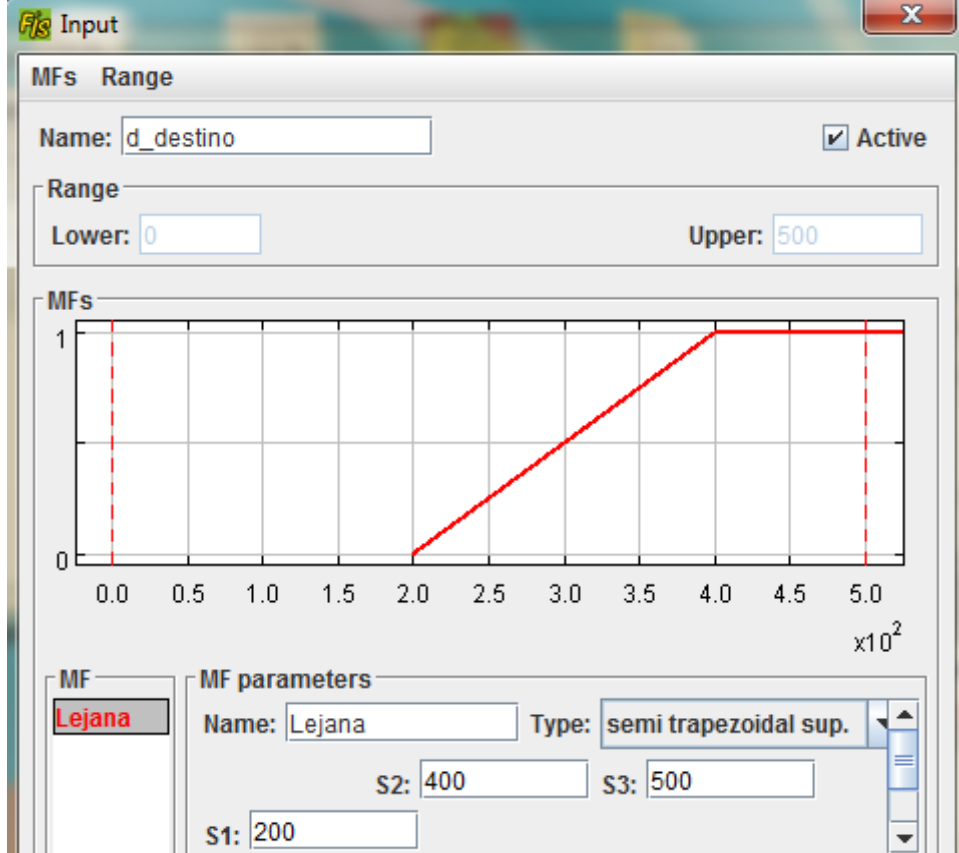
lejana = [0,25 0,5 0,75 1 1]

rapida = [0 0,2 0,6 1]


$$v_{1(40)} = \max(\min(0,75;0); \min(1;0); \min(0,75;0); \min(0;0); \min(0;0))$$

$$v^* = [0 \quad 0,2 \quad 0,6 \quad 0,75] = v^*$$

Siendo un hecho que está entre las distancias MEDIAS y LEJANAS; es de esperar que v^* esté entre las velocidades MEDIA y RÁPIDA

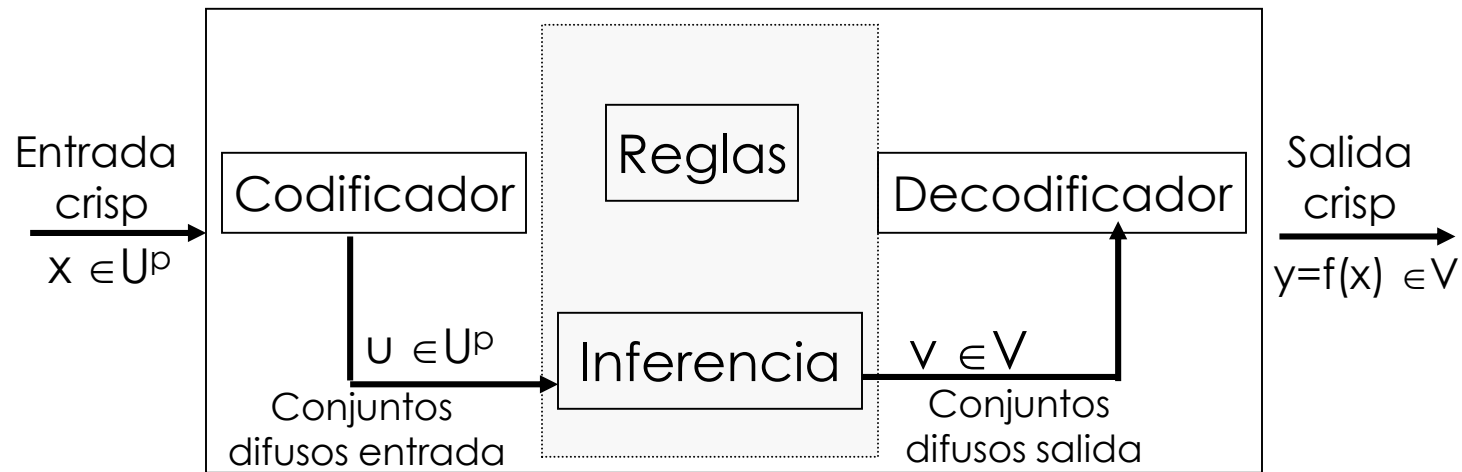



$$v^* = \begin{bmatrix} 40 & 50 & 70 & 90 \\ 0 & 0,2 & 0,6 & 0,75 \end{bmatrix} = v^*$$



Métodos de Defuzificación

- La salida de un proceso de inferencia es un conjunto difuso, en procesos en línea se requieren valores crisp





Métodos de Defuzificación


- Por ej.:

Centro de Gravedad

$$y = \frac{\sum_i b_i \int \mu(i)}{\sum_i \int \mu(i)}$$

Centros Promediados

$$y = \frac{\sum_i b_i \mu_{\text{premisa}}(i)}{\sum_i \mu_{\text{premisa}}(i)}$$






Resumen de tareas: FIS

- Definir las variables de entradas y salidas
- Definir el universo de discurso
- Determinar el número de funciones de pertenencia
- Distribuir las funciones de pertenencia
- Definir el método de borrosificación
- Definir el método de inferencia
- Definir el método de desborrosificación
- Examinar la conducta del modelo y la superficie de salida: Redefinir reglas Ejemplo

En resumen: Cuándo usar lógica borrosa



- En procesos **complejos**, si no existe un modelo de solución sencillo
- En procesos **no lineales**
- Cuando haya que introducir la experiencia de un operador "**experto**" que se base en conceptos imprecisos obtenidos de su experiencia
- Cuando ciertas partes del sistema a controlar son **desconocidas** y no pueden medirse de forma **fiable**
- Cuando el ajuste de una variable puede producir el desajuste de otras
- En general cuando se desea representar y operar con conceptos que tengan **imprecisión** o **incertidumbre**




En resumen: Desventajas

- Estabilidad: No hay garantía teórica que un sistema difuso no tenga un comportamiento caótico y no siga siendo estable, aunque tal posibilidad parece ser baja debido a los resultados obtenidos hasta ahora
- La determinación de las funciones de pertenencia y las reglas no siempre son sencillas
- La verificación de los modelos y sistemas borrosos expertos requiere de gran cantidad de pruebas



Implicaciones borrosas: I



Caso *crisp*: $x \rightarrow y := \neg x \vee y$

Una función $I: [0,1]^2 \rightarrow [0,1]$ es llamada “fuzzy implication” si satisface las siguientes propiedades (Fundamentals of fuzzy sets, D. Dubois, H. Prade)

I1. $I(0,0) = I(0,1) = I(1,1) = 1; I(1,0) = 0$

I2. If $x \leq z$ then $I(x,y) \geq I(z,y)$ for all $y \in [0,1]$

I3. If $y \leq t$ then $I(x,y) \leq I(x,t)$ for all $x \in [0,1]$

I4. $I(0, x) = 1;$

I5. $I(x, 1) = 1;$

I6. $I(1, x) = x$ for all $x \in [0,1]$

I7. $I(x, I(y, z)) = I(y, I(x, z))$

I8. $x \leq y$ if and only if $I(x,y) = 1$

I9. $N(x) := I(x,0)$ is a strong negation

I10. $I(x,y) \geq y$

I11. $I(x,x) = 1$


I12. $I(x,y) = I(N(y), N(x))$

I13. I is a continuous function

Def: An S -implication associated with a t-conorm S and a strong negation N is defined by

$$I_{S,N}(x,y) := S(N(x),y) \quad (x,y \in [0,1]).$$

FISPRO: Trabajando a partir de datos



- Generación de particiones
 - Regular
 - K-means
 - HFP
- Generación de reglas
 - FPA
 - Wang & Mendel
 - Árbol de decisión